Penerapan Metode Klasifikasi untuk Memprediksi Pelanggan Repeat Buyer pada Industri E-Commerce Indonesia Menggunakan Random Forest, Decision Tree, dan Naive Bayes

Roudhotul Izzah Imroatunnadhiroh[1]*, Reihan Rachma Shafira[2], Hawa Shabilla Fanfa[3]

[1]First Author Affiliation, Correspondence author should be indicated by * symbol (Calibri 9 Center)
[2]Department of Biology, Faculty of Mathematics and Natural Sciences, University of Brawijaya, Malang, Indonesia
[3]Laboratorium of Physiology, Faculty of Medicine, University of Brawijaya, Malang, Indonesia

Abstract

Peningkatan pengalaman pelanggan menjadi salah satu fokus utama dalam persaingan e-commerce di Indonesia, sehingga perusahaan perlu memanfaatkan data transaksi secara optimal untuk memahami perilaku pembelian pengguna. Banyak perusahaan belum mampu mengolah data tersebut secara mendalam, padahal informasi yang tersimpan berpotensi menggambarkan kecenderungan pelanggan dalam melakukan pembelian ulang. Teknik klasifikasi dalam penambangan data menyediakan pendekatan yang efektif untuk mengidentifikasi pola tersebut. Penelitian ini menggunakan Repeat Buyer E-commerce Dataset dari Mauludiah (2025) untuk membangun model prediksi pelanggan repeat buyer menggunakan tiga algoritma, yaitu Random Forest, Decision Tree, dan Naive Bayes. Proses penelitian meliputi pembersihan data, transformasi variabel, dan pemisahan data latih serta data uji sebelum dilakukan pemodelan. Hasil pengujian menunjukkan bahwa Random Forest memiliki kinerja paling unggul dibandingkan dua algoritma lainnya, dengan tingkat akurasi yang lebih stabil pada berbagai skenario pembelajaran. Decision Tree memberi hasil yang cukup baik namun sensitif terhadap variasi data, sementara Naive Bayes menunjukkan performa paling rendah. Hal ini memberikan gambaran bahwa penggunaan algoritma berbasis ensemble lebih sesuai dalam memprediksi potensi pembelian ulang sehingga dapat mendukung perusahaan dalam menyusun strategi retensi yang lebih efektif.

Keywords: *Repeat Buyer, E-commerce, Data Mining, Random Forest, Decision Tree, Naive Bayes*

PENDAHULUAN

Industri e-commerce di Indonesia berkembang sangat cepat sehingga menciptakan persaingan yang semakin kompetitif di antara para pelaku bisnis. Dalam kondisi tersebut, perusahaan tidak hanya dituntut untuk menarik pelanggan baru, tetapi juga harus mampu mempertahankan pelanggan yang sudah pernah bertransaksi agar kembali melakukan pembelian ulang (*repeat buying*). Pelanggan repeat buyer memiliki nilai strategis karena biaya mempertahankan pelanggan jauh lebih rendah dibandingkan biaya akuisisi pelanggan baru [1]. serta berkontribusi signifikan terhadap peningkatan *customer lifetime value* (CLV) [2], [3].

Namun, dalam kenyataannya banyak perusahaan e-commerce menghadapi kendala berupa keterbatasan data pelanggan, baik dari sisi variabel yang tersedia maupun akurasi data transaksi. Keterbatasan ini membuat perusahaan kesulitan mengenali pelanggan yang berpotensi melakukan pembelian ulang. Tanpa kemampuan prediksi *repeat buyer*, strategi promosi sering kali menjadi kurang tepat sasaran, menyebabkan biaya pemasaran meningkat dan peluang untuk meningkatkan retensi pelanggan tidak dimanfaatkan secara optimal [4], [5].

Perkembangan teknologi analitik berbasis data memungkinkan penerapan data mining untuk mengatasi tantangan tersebut melalui pemodelan prediksi perilaku pelanggan. Berbagai penelitian sebelumnya menunjukkan efektivitas metode klasifikasi dalam memprediksi perilaku *repeat buyer*. Pada penelitian, Suhanda et al. menemukan bahwa tingkat retensi pelanggan pada platform e-commerce mencapai 81,12%, sedangkan tingkat churn sebesar 18,87%, menunjukkan pentingnya pendekatan prediktif untuk mempertahankan pelanggan yang berisiko churn [6]. Penelitian Dewi et al. juga membuktikan efektivitas metode klasifikasi melalui perbandingan tiga algoritma, di mana Decision Tree memperoleh akurasi 90,91%, Naïve Bayes menghasilkan akurasi 37,50%, dan Random Forest menjadi yang terbaik dengan akurasi 93,94% dalam memprediksi repeat order

pelanggan e-commerce [5]. Bukti-bukti penelitian tersebut menegaskan bahwa metode klasifikasi memiliki potensi besar untuk mendukung strategi retensi pelanggan berbasis data.

Berbagai penelitian menunjukkan bahwa algoritma klasifikasi seperti Random Forest, Decision Tree, dan Naive Bayes efektif dalam mengidentifikasi pola perilaku pelanggan dan memprediksi potensi pembelian ulang berdasarkan data transaksi [6], [7]. Dengan membangun model prediksi *repeat buyer*, perusahaan dapat menargetkan promosi secara lebih akurat, sehingga mampu menekan biaya pemasaran sekaligus meningkatkan retensi pelanggan.

Selain itu, ketersediaan dataset transaksi e-commerce yang semakin mudah diakses, termasuk dataset publik yang berfokus pada perilaku pembelian, memberikan peluang bagi penelitian akademis untuk menguji berbagai metode prediksi secara lebih komprehensif. Penggunaan dataset yang representatif tidak hanya memperkuat validitas model yang dikembangkan, tetapi juga memungkinkan evaluasi performa antar-algoritma secara objektif, sehingga temuan penelitian dapat digunakan langsung dalam implementasi di lapangan.

Situasi ini menunjukkan adanya urgensi penelitian karena masih terdapat kesenjangan antara kebutuhan industri dalam meningkatkan retensi pelanggan dan pemilihan model prediksi yang sesuai. Walaupun sudah ada berbagai metode yang diusulkan, masih sedikit penelitian yang menguji kinerja beberapa algoritma klasifikasi secara bersamaan menggunakan dataset e-commerce Indonesia yang berfokus pada repeat buyer. Dengan demikian, analisis komparatif dibutuhkan untuk menentukan algoritma yang paling efektif, akurat, dan konsisten ketika diterapkan pada karakteristik data lokal.

Penelitian ini mengusulkan penerapan metode klasifikasi menggunakan Random Forest, Decision Tree, dan Naive Bayes pada dataset transaksi e-commerce Indonesia untuk memprediksi pelanggan yang berpotensi menjadi *repeat buyer*. Hasil dari penelitian ini diharapkan dapat membantu perusahaan e-commerce dalam mengembangkan strategi pemasaran yang lebih efektif, efisien, dan tepat sasaran.

LITERATURE REVIEW

E-Commerce

E-commerce merupakan sistem perdagangan elektronik yang memungkinkan proses penjualan, pembelian, dan pertukaran informasi dilakukan melalui jaringan internet secara real-time. Perkembangan e-commerce dalam beberapa tahun terakhir semakin pesat berkat kemajuan teknologi digital seperti kecerdasan buatan, Internet of Things (IoT), big data analytics, dan blockchain yang meningkatkan efisiensi proses bisnis serta pengalaman pelanggan [8]. Integrasi teknologi tersebut tidak hanya mempercepat transaksi, tetapi juga memperluas skala operasional dan meningkatkan kemampuan perusahaan dalam memahami perilaku konsumen melalui analisis data.

Menurut studi E-Commerce Meets Emerging Technologies, pemanfaatan teknologi baru mampu meningkatkan otomatisasi, keamanan transaksi, serta personalisasi layanan sehingga mendorong pertumbuhan e-commerce secara berkelanjutan [8]. Sementara itu, penelitian lain menunjukkan bahwa pandemi COVID-19 menjadi katalis utama perubahan perilaku belanja, di mana konsumen beralih dari transaksi fisik ke digital dalam skala besar. Pergeseran ini membuat e-commerce semakin dominan sebagai model bisnis modern dan menjadi pilar utama dalam ekosistem ekonomi digital global [9]. Oleh karena itu, pemahaman mengenai konsep dan dinamika e-commerce sangat penting dalam pengembangan sistem prediktif, analitik pelanggan, maupun strategi pemasaran pada platform digital.

Repeat Buyer

Repeat buyer merupakan pelanggan yang melakukan pembelian lebih dari satu kali pada platform e-commerce dan dianggap sebagai aset penting dalam strategi retensi pelanggan. Pelanggan tipe ini memiliki nilai ekonomi tinggi karena biaya mempertahankan mereka lebih rendah dibandingkan biaya akuisisi pelanggan baru, serta berkontribusi pada peningkatan customer lifetime value (CLV). Perilaku repeat buyer dapat diprediksi melalui pola transaksi sebelumnya, seperti frekuensi pembelian, jenis

produk yang sering dibeli, serta waktu antar pembelian [10]. Penelitian tersebut menekankan bahwa pemanfaatan machine learning mampu mengidentifikasi karakteristik pelanggan yang berpotensi melakukan pembelian ulang dengan tingkat akurasi yang cukup tinggi.

Data interaksi tingkat rendah, seperti durasi kunjungan, perilaku klik, dan urutan navigasi pengguna, memiliki pengaruh signifikan dalam memprediksi kemungkinan pembelian ulang [11]. Hal ini menunjukkan bahwa repeat buying tidak hanya dipengaruhi oleh pembelian sebelumnya, tetapi juga oleh interaksi mikro selama proses penelusuran produk. Pemahaman mendalam mengenai repeat buyer penting untuk mengembangkan strategi pemasaran yang lebih personal, meningkatkan pengalaman pelanggan, dan mengoptimalkan rekomendasi produk pada platform e-commerce.

Data Mining

Data mining merupakan proses sistematis untuk mengekstraksi pola, pengetahuan, dan informasi yang bernilai dari data dalam jumlah besar. Proses ini menggabungkan teknik statistik, kecerdasan buatan, dan pembelajaran mesin untuk mengidentifikasi hubungan tersembunyi dalam data, sehingga dapat digunakan untuk pengambilan keputusan berbasis fakta. Pemilihan strategi data mining harus disesuaikan dengan jenis data yang dianalisis, karena setiap teknik memiliki karakteristik berbeda dalam menangani data numerik, kategorikal, teks, maupun data tidak terstruktur [12]. Efektivitas data mining meningkat ketika metode yang digunakan sesuai dengan tipe data dan tujuan analisis.

Implementasi data mining dalam bisnis, khususnya pada usaha kecil dan menengah (UKM), mampu memberikan keunggulan kompetitif melalui pemahaman perilaku pelanggan, optimalisasi proses internal, dan peramalan permintaan [13]. Integrasi antara data mining dan business intelligence terbukti dapat meningkatkan kualitas keputusan manajerial, terutama dalam lingkungan bisnis yang kompetitif dan berbasis data. Oleh karena itu, data mining menjadi fondasi utama dalam pengembangan model prediksi, segmentasi pelanggan, sistem rekomendasi, serta berbagai aplikasi analitik lainnya dalam domain e-commerce dan teknologi informasi.

Klasifikasi

Klasifikasi merupakan teknik utama dalam data mining dan machine learning yang bertujuan mengelompokkan data ke dalam kelas tertentu berdasarkan pola yang dipelajari dari data historis. Proses ini meliputi pembelajaran dari data berlabel (*supervised learning*), pembuatan model, dan pengujian performa menggunakan metrik evaluasi seperti akurasi, precision, recall, dan F1-score. Algoritma klasifikasi banyak digunakan dalam analisis perilaku pelanggan, termasuk prediksi churn, karena kemampuannya menangani dataset kompleks serta menghasilkan keputusan yang cepat dan terstruktur [14]. Pemilihan algoritma sangat memengaruhi kualitas hasil klasifikasi, terutama ketika data memiliki distribusi yang tidak seimbang atau fitur dengan tingkat korelasi tinggi.

Setiap algoritma memiliki keunggulan dan kelemahan tergantung karakteristik data yang digunakan [15]. Misalnya, algoritma berbasis pohon lebih mudah diinterpretasikan, sedangkan model seperti Support Vector Machine atau ensemble memiliki akurasi lebih tinggi pada data dengan pola non-linear. Temuan ini menunjukkan bahwa klasifikasi tidak hanya bergantung pada algoritma, tetapi juga pada proses pra-pemrosesan, pemilihan fitur, dan parameterisasi model. Oleh karena itu, pemahaman mendalam mengenai teknik klasifikasi menjadi dasar penting dalam pengembangan sistem prediksi yang andal, termasuk dalam konteks e-commerce dan perilaku pelanggan.

Random Forest

Random Forest merupakan algoritma ensemble learning berbasis banyak pohon keputusan (decision trees) yang digabungkan untuk menghasilkan prediksi yang lebih akurat, stabil, dan tahan terhadap overfitting. Pada dasarnya, Random Forest membangun sejumlah pohon secara acak melalui teknik bootstrap aggregating (bagging), di mana setiap pohon dilatih menggunakan sampel data dan subset

fitur yang berbeda. Proses ini membuat model mampu menangkap variasi pola data yang kompleks serta meningkatkan kemampuan generalisasi. Penggunaan Random Forest terbukti efektif dalam membangun model prediktif karena mampu mengelola data dengan distribusi tidak merata dan variabel dengan korelasi tinggi tanpa mengalami penurunan performa signifikan [16].

Random Forest memiliki keunggulan dalam memproses data numerik maupun kategorikal, serta memberikan feature importance yang membantu peneliti mengidentifikasi variabel paling berpengaruh terhadap hasil prediksi [17]. Dalam konteks ilmu data, hal ini sangat penting karena memungkinkan interpretasi yang lebih baik terhadap faktor-faktor yang berkontribusi pada model. Keunggulan lain Random Forest adalah kestabilan akurasinya pada berbagai percobaan, sehingga algoritma ini sering dipilih untuk kasus prediksi, klasifikasi, maupun regresi dalam berbagai domain, termasuk pendidikan, kesehatan, dan e-commerce.

Decision Tree

Decision Tree merupakan salah satu algoritma klasifikasi paling populer dalam machine learning karena kemampuannya menghasilkan model yang mudah dipahami dan diinterpretasikan. Algoritma ini bekerja dengan membagi data ke dalam cabang-cabang berdasarkan aturan keputusan (*if–then*) yang ditentukan oleh nilai fitur paling informatif. Proses pemilihan fitur umumnya menggunakan ukuran seperti information gain, entropy, atau Gini index. Decision Tree banyak digunakan dalam berbagai kasus klasifikasi karena mampu menangani data kategorikal maupun numerik secara efisien serta memberikan hasil prediksi yang cepat [18]. Decision Tree sangat membantu dalam analisis perilaku data karena struktur modelnya menyerupai diagram alur.

Algoritma berbasis Decision Tree banyak diterapkan dalam domain kecerdasan buatan modern karena kemampuannya mengenali pola non-linear, serta fleksibilitasnya dalam digabungkan dengan teknik lain seperti ensemble learning atau pruning untuk meningkatkan akurasi [19]. Meskipun sederhana, Decision Tree dapat mengalami overfitting ketika pohon tumbuh terlalu dalam. Oleh karena itu, metode seperti pruning dan cross-validation sering diterapkan untuk meningkatkan kemampuan generalisasi. Dengan keunggulan interpretabilitas dan kinerja yang stabil, Decision Tree menjadi algoritma fundamental dalam banyak penelitian data mining dan sistem prediksi.

Naive Bayes

Naive Bayes merupakan algoritma klasifikasi berbasis probabilitas yang didasarkan pada Teorema Bayes dengan asumsi bahwa setiap fitur saling independen satu sama lain. Meskipun asumsi independensi tersebut jarang sepenuhnya terpenuhi dalam data dunia nyata, algoritma ini tetap menunjukkan performa yang baik pada berbagai kasus klasifikasi. Naive Bayes memiliki keunggulan utama berupa efisiensi komputasi, kemudahan implementasi, serta kemampuan beradaptasi pada dataset berukuran besar dengan jumlah fitur yang banyak [20]. Metode ini dapat memberikan akurasi tinggi pada kasus penentuan kategori, terutama ketika distribusi data mendekati pola probabilistik yang stabil.

Naive Bayes sangat efektif digunakan untuk analisis sentimen dan klasifikasi teks karena sifatnya yang mampu mengolah fitur dalam jumlah besar secara cepat. Naive Bayes cenderung bekerja optimal pada data yang tidak terlalu kompleks dan tidak memerlukan proses training yang berat. Dalam konteks machine learning, Naive Bayes sering dijadikan baseline model untuk membandingkan performa algoritma lain karena stabilitasnya dan kemampuannya memberikan hasil yang konsisten. Dengan karakteristik tersebut, Naive Bayes menjadi algoritma penting dalam pengembangan sistem prediksi, text mining, dan klasifikasi berbasis data [21].

MATERIAL AND METHOD

Dalam penelitian ini, digunakan pendekatan sistematis mulai dari pengumpulan data, pra-pemrosesan, transformasi data, hingga proses Data Mining untuk menghasilkan prediksi yang akurat. Alur lengkap metode penelitian dapat dilihat pada gambar dibawah ini

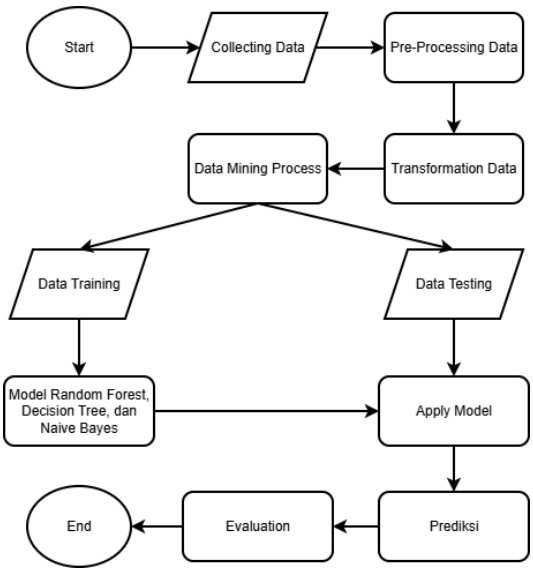

Gambar 1. Flowchart Proses Data Mining

Gambar tersebut menunjukkan rangkaian proses penelitian yang dimulai dari tahap Collecting Data, dilanjutkan ke Pre-Processing Data untuk membersihkan data dari ketidakteraturan, kemudian ke Transformation Data yang berfungsi menyesuaikan bentuk data agar dapat diproses oleh algoritma. Setelah itu, data memasuki tahap Data Mining Process, yang kemudian bercabang menjadi dua proses, yaitu Data Training dan Data Testing. Data Training digunakan untuk membangun model menggunakan algoritma Random Forest, Decision Tree, dan Naive Bayes, sementara Data Testing digunakan untuk menguji kemampuan model dalam melakukan prediksi. Hasil prediksi tersebut selanjutnya dievaluasi untuk menentukan performa dan akurasi model secara keseluruhan.

Collecting Data

Pengumpulan data merupakan tahap awal yang sangat penting dalam proses penelitian karena kualitas data akan menentukan kualitas model yang dihasilkan. Pada penelitian ini, data dikumpulkan menggunakan dataset yang berisi informasi pembelian pelanggan, seperti tanggal transaksi, kategori produk, jumlah pembelian, wilayah, usia, serta jenis kelamin pelanggan. Atribut-atribut ini dipilih karena memiliki relevansi langsung terhadap analisis perilaku pelanggan dan proses klasifikasi repeat buyer.

Pemilihan dataset dilakukan dengan mempertimbangkan kelengkapan atribut, ketersediaan label repeat/non-repeat, serta representativitas data terhadap kondisi e-commerce di Indonesia. Sumber data bersifat arsip, sehingga tidak diperlukan pengambilan data melalui survei ataupun observasi langsung.

Pre-Processing Data

Tahap pre-processing merupakan proses awal untuk memastikan bahwa data mentah berada dalam kondisi yang layak sebelum dianalisis lebih lanjut. Pada tahap ini, dilakukan berbagai proses pembersihan seperti penghapusan duplikasi, penanganan missing value, normalisasi format teks, serta penyesuaian struktur data agar konsisten. Kualitas data mentah secara langsung memengaruhi performa model, sehingga pembersihan dan verifikasi data menjadi langkah yang wajib dilakukan sebelum masuk ke tahap transformasi atau pemodelan [22]. Selain itu, penerapan standar kebersihan data menjadi faktor kunci untuk memastikan penelitian dapat direplikasi dengan benar [23].

Proses pembersihan ini juga mencakup identifikasi dan penanganan noise, yaitu data yang tidak relevan atau bersifat outlier dan berpotensi mengganggu pembelajaran model. Misalnya nilai ekstrem yang tidak mungkin terjadi, baris data kosong, atau karakter-karakter asing yang muncul akibat kesalahan input. Penghapusan noise mampu meningkatkan akurasi model klasifikasi hingga lebih dari 10% pada beberapa kasus data publik [22]. Konsistensi format seperti penyamaan huruf (*lowercase*), penghapusan spasi berlebih, serta penyelarasan format tanggal membuat dataset menjadi lebih homogen dan dapat diproses tanpa risiko error.

Selain pembersihan dasar, pre-processing juga berkaitan dengan validasi semantik data, misalnya menyesuaikan label kategori yang tidak konsisten, memeriksa duplikasi baris, serta mengecek kelengkapan kolom. Beberapa penelitian nasional menekankan bahwa pengecekan semantik sangat penting, terutama ketika data dikumpulkan dari responden manusia yang rawan kesalahan input. Setelah seluruh proses pembersihan dilakukan, data yang sudah rapi siap digunakan pada tahap transformasi untuk keperluan algoritma.

Transformation Data

Tahap transformation berfokus pada mengubah representasi data agar kompatibel dengan algoritma Data Mining. Banyak algoritma hanya menerima input numerik, sehingga variabel kategori perlu diubah menjadi angka melalui teknik seperti Label Encoding atau One-Hot Encoding. Pemilihan metode encoding yang tepat sangat berpengaruh pada kinerja model, terutama pada algoritma yang sensitif terhadap hubungan antar-fitur [24]. Selain encoding, proses normalisasi atau scaling juga penting untuk menyamakan skala antar-fitur,

terutama jika dataset memiliki rentang nilai yang sangat berbeda.

Tahap transformasi sering dilanjutkan dengan pembuatan fitur baru (*feature engineering*) untuk memperkaya informasi yang tersedia. Fitur yang baik dapat meningkatkan akurasi model lebih signifikan dibandingkan sekadar menggunakan algoritma kompleks. *Feature engineering* seperti binning, kombinasi antar-variabel, atau ekstraksi pola berhasil meningkatkan performa model secara signifikan [25]. Setelah seluruh transformasi ini dilakukan, dataset siap digunakan pada tahap pemodelan dalam proses Data Mining.

Data Mining Process

Pada tahap ini, dijalankan proses pembangunan model menggunakan algoritma yang dipilih, sehingga Data Mining Process berfokus pada pengolahan data untuk menemukan pola, hubungan, atau struktur tertentu yang relevan dengan tujuan penelitian. Bagian pertama dari Data Mining Process adalah training, yaitu proses ketika algoritma mempelajari pola dari data training. Bagian pertama dari Data Mining Process adalah training, yaitu proses ketika algoritma mempelajari pola dari data training [26].

Bagian kedua adalah testing, yaitu tahap pengujian model menggunakan data yang tidak digunakan pada proses training. Tahap ini bertujuan untuk menilai kinerja model secara objektif, memeriksa tingkat akurasi, menghitung error, serta mengevaluasi apakah model mengalami overfitting atau justru mampu bekerja baik pada data baru. Pemisahan data training dan testing merupakan prinsip dasar dalam machine learning untuk memastikan kemampuan generalisasi model terhadap data dunia nyata [27]. Evaluasi hasil testing menjadi dasar untuk menentukan apakah model dapat dilanjutkan, diperbaiki, atau perlu dibangun ulang.

Prediksi & Evaluasi

Tahap evaluation bertujuan mengukur performa model yang telah dibangun menggunakan berbagai metrik seperti akurasi, precision, recall, F1-score, dan confusion matrix. Metrik-metrik ini memberikan gambaran mengenai seberapa baik model mampu mengklasifikasikan data sesuai dengan label sebenarnya. Penggunaan beberapa metrik sekaligus penting untuk mendapatkan penilaian performa yang lebih komprehensif, karena akurasi saja sering tidak cukup untuk dataset yang tidak seimbang. Evaluasi biasanya memanfaatkan metrik seperti accuracy, precision, recall, F1-score, serta confusion matrix. Selain itu, dapat menggunakan ROC-AUC untuk menilai kemampuan diskriminatif model pada data yang mengandung probabilitas prediksi [28]. Dalam tahap ini, beberapa model dibandingkan untuk menentukan algoritma mana yang memberikan performa terbaik.

Setelah model terbaik dipilih melalui tahap evaluasi, proses berlanjut ke tahap prediction. Model yang memiliki performa tertinggi kemudian digunakan untuk memprediksi data baru, mengklasifikasikan kategori, atau menghasilkan output sesuai dengan tujuan penelitian. Misalnya, model dapat digunakan untuk memprediksi apakah pelanggan termasuk dalam kategori repeat buyer. Dengan demikian, tahap prediksi merupakan penerapan praktis dari model yang telah terverifikasi performanya pada tahap evaluasi.

RESULT AND DISCUSSION

Collecting Data

Pada tahap Collecting Data, dilakukan pemeriksaan awal terhadap struktur, karakteristik, dan konten dataset untuk memperoleh gambaran umum mengenai data yang akan dianalisis. Langkah ini mencakup identifikasi jenis variabel, pola distribusi, serta potensi inkonsistensi yang mungkin memengaruhi proses analisis selanjutnya. Selain itu, pemahaman terhadap konteks setiap atribut sangat penting agar tahapan pra-pemrosesan dan pemodelan dapat dilakukan secara lebih akurat. Untuk memberikan gambaran awal mengenai bentuk dan isi data, berikut ditampilkan cuplikan lima baris pertama dari dataset menggunakan fungsi df.head().

	No	Trx_Date	Cust_ID	Age	Gender	AREA	Product_ID	Product_Name	Category	Amount
0	1	6/1/2022	CTR0200437	49	Laki-laki	Aceh	HP-PV15	Laptop HP Pavilion 15	Computer	1
1	2	6/1/2022	CTR0200460	18	Perempuan	Bandung	192021232	Hair Mask CDE	Hair Treatment	1
2	3	6/1/2022	CTR0200553	42	Perempuan	Banjarmasin	192021232	Hair Mask CDE	Hair Treatment	7
3	4	6/1/2022	CTR0200581	42	Laki-laki	Batam	IKE-KALLAX	Rak Buku IKEA Kallax	Home Appliances	5
4	5	6/1/2022	CTR0200563	39	Perempuan	Cirebon	232425275	Perfume OPQ	Cosmetics	1

Gambar 2. Hasil pemeriksaan awal dataset untuk memahami variabel dan isi data

Dataset ini berisi transaksi penjualan yang mencakup berbagai kategori produk, mulai dari perangkat elektronik seperti laptop, produk perawatan seperti hair mask, hingga perlengkapan rumah tangga seperti rak buku.

Data pelanggan yang tercatat juga berasal dari berbagai wilayah di Indonesia, sehingga memberikan variasi geografis yang cukup luas dalam analisis. Selain itu, terdapat perbedaan jumlah pembelian pada setiap transaksi, di mana beberapa pelanggan melakukan pembelian lebih dari satu unit produk, misalnya pembelian hingga 7 unit pada kategori Hair Treatment. Informasi penting lainnya seperti usia dan jenis kelamin pelanggan tersedia secara lengkap, sehingga data ini dapat digunakan untuk menganalisis pola perilaku pelanggan berdasarkan demografi.

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 1000 entries, 0 to 999
Data columns (total 10 columns):
 #   Column        Non-Null Count  Dtype
---  ------        --------------  -----
 0   No            1000 non-null   int64
 1   Trx_Date      1000 non-null   object
 2   Cust_ID       1000 non-null   object
 3   Age           1000 non-null   int64
 4   Gender        1000 non-null   object
 5   AREA          1000 non-null   object
 6   Product_ID    1000 non-null   object
 7   Product_Name  1000 non-null   object
 8   Category      1000 non-null   object
 9   Amount        1000 non-null   int64
dtypes: int64(3), object(7)
memory usage: 78.3+ KB
```

Gambar 3. Informasi Tipe Data dan Jumlah Kolom pada Dataset

Dataset yang digunakan memiliki kelengkapan data sebesar 100% tanpa adanya nilai yang hilang (*missing value*), sehingga tidak diperlukan proses pembersihan terkait data kosong. Struktur dataset terdiri dari kombinasi data numerik dan kategorikal, sehingga diperlukan tahap pengolahan awal seperti encoding pada variabel kategorikal melalui label encoding atau one-hot encoding. Selain itu, beberapa variabel numerik yang memiliki distribusi tidak normal atau skewed, seperti Amount, memerlukan normalisasi atau transformasi log agar lebih sesuai untuk proses pemodelan. Secara keseluruhan, ukuran dataset tergolong kecil dan efisien sehingga mudah diolah pada tahap data preprocessing maupun pemodelan machine learning.

	No	Age	Amount
count	1000.000000	1000.000000	1000.000000
mean	500.500000	38.860000	1.820000
std	288.819436	9.839167	2.587333
min	1.000000	18.000000	1.000000
25%	250.750000	30.000000	1.000000
50%	500.500000	40.000000	1.000000
75%	750.250000	47.000000	2.000000
max	1000.000000	60.000000	30.000000

Gambar 4. Statistik deskriptif untuk variabel numerik pada dataset

Berdasarkan hasil statistik deskriptif pada Gambar 4, dapat diketahui bahwa dataset memiliki tiga variabel numerik, yaitu *No*, *Age*, dan *Amount*. Kolom *Age* memiliki nilai rata-rata sebesar 38,86 tahun dengan rentang usia antara 18 hingga 60 tahun. Sementara itu, nilai *Amount* sebagai jumlah pembelian menunjukkan rata-rata sebesar 1,82 dengan standar deviasi 2,59, yang mengindikasikan adanya variasi pembelian antar pelanggan. Nilai minimum *Amount* adalah 1 dan maksimum mencapai 30, menandakan adanya beberapa transaksi dengan jumlah pembelian yang jauh lebih tinggi dibandingkan transaksi lainnya. Secara keseluruhan, statistik deskriptif ini memberikan gambaran awal mengenai distribusi dan sebaran data numerik dalam dataset sebelum dilakukan proses analisis lebih lanjut.

```
# Mengecek jumlah baris duplikat
df.duplicated().sum()
```

```
np.int64(0)
```

Gambar 5. Hasil pengecekan jumlah baris duplikat pada dataset

Berdasarkan hasil pengecekan duplikasi pada Gambar 5, diperoleh nilai sebesar 0 yang menunjukkan bahwa tidak terdapat baris duplikat dalam dataset. Hal ini berarti setiap entri atau transaksi pada data bersifat unik dan tidak ada pengulangan data yang sama persis pada seluruh kolom. Dengan demikian, proses pembersihan data terkait duplikasi tidak diperlukan, sehingga dataset dapat langsung digunakan untuk tahap analisis berikutnya tanpa risiko distorsi akibat data ganda.

```
# Hitung jumlah outlier tiap kolom
outlier_counts = outliers.sum(axis=0)

outlier_counts
```

```
array([ 0, 17])
```

Gambar 6. Hasil deteksi outlier pada variabel numerik menggunakan metode Z-Score.

Berdasarkan hasil deteksi outlier pada Gambar 6 menggunakan metode Z-Score dengan threshold 3, diketahui bahwa variabel *Age* tidak memiliki outlier (0 data), sedangkan variabel *Amount* memiliki 17 data yang teridentifikasi sebagai outlier. Hal ini menunjukkan bahwa penyimpangan ekstrem lebih banyak terjadi pada jumlah pembelian (*Amount*), kemungkinan karena adanya beberapa transaksi dengan nilai pembelian yang jauh lebih besar dibandingkan transaksi lainnya. Temuan ini penting untuk

dipertimbangkan dalam tahap preprocessing, karena keberadaan outlier dapat mempengaruhi hasil analisis maupun kinerja model machine learning apabila tidak ditangani dengan baik.

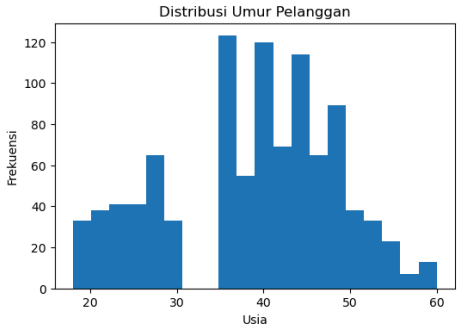

Gambar 7. Histogram Distribusi Usia Pelanggan

Berdasarkan Gambar 7, distribusi usia pelanggan terlihat menyebar dari rentang usia sekitar 18 hingga 60 tahun. Mayoritas pelanggan berada pada kelompok usia produktif, khususnya antara 35–50 tahun, yang menunjukkan bahwa segmen ini merupakan pengguna layanan yang dominan. Frekuensi tertinggi tampak pada rentang usia sekitar 35–45 tahun. Pola distribusi ini memberikan indikasi bahwa strategi pemasaran dan layanan dapat difokuskan pada kelompok usia dewasa produktif, karena mereka merupakan mayoritas dalam dataset. Distribusi juga tampak cukup beragam tanpa adanya pencilan ekstrem, sehingga data usia pelanggan dapat dianggap representatif.

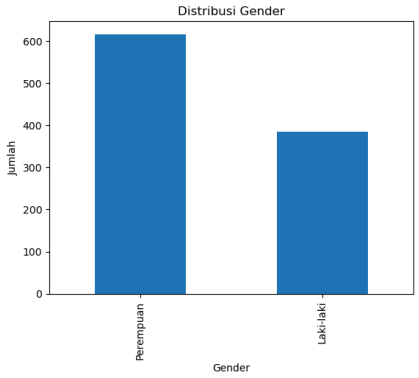

Gambar 8. Grafik Distribusi Gender Pelanggan

Gambar 8 menunjukkan distribusi gender pelanggan berdasarkan data yang tersedia. Dari grafik terlihat bahwa jumlah pelanggan perempuan lebih tinggi dibandingkan dengan pelanggan laki-laki. Kelompok perempuan mendominasi dengan jumlah lebih dari 600 orang, sedangkan pelanggan laki-laki berada pada kisaran sekitar 380 orang. Hal ini mengindikasikan bahwa pelanggan perempuan merupakan segmen terbesar dalam dataset dan memiliki kontribusi signifikan terhadap keseluruhan populasi pelanggan. Informasi ini dapat membantu dalam penentuan strategi layanan maupun pemasaran yang lebih tepat sasaran berdasarkan dominasi gender.

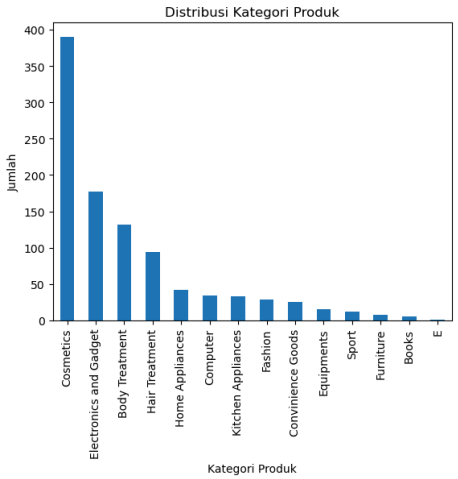

Gambar 9. Grafik Distribusi Kategori Produk

Gambar 9 menggambarkan distribusi jumlah transaksi berdasarkan kategori produk. Dari grafik terlihat bahwa kategori Cosmetics merupakan kategori dengan transaksi terbanyak, mencapai hampir 400 transaksi. Kategori berikutnya yang juga cukup dominan adalah Electronics and Gadget, Body Treatment, dan Hair Treatment, yang menunjukkan bahwa produk kecantikan dan perawatan diri memiliki minat cukup tinggi di kalangan pelanggan. Sebaliknya, beberapa kategori seperti Books, Furniture, dan kategori kecil lain hanya memiliki jumlah transaksi yang sangat sedikit. Distribusi ini menunjukkan adanya kecenderungan pelanggan untuk lebih banyak membeli produk kecantikan dan elektronik dibandingkan kategori lainnya, sehingga kategori-kategori tersebut dapat menjadi fokus utama dalam strategi pemasaran atau perencanaan stok perusahaan.

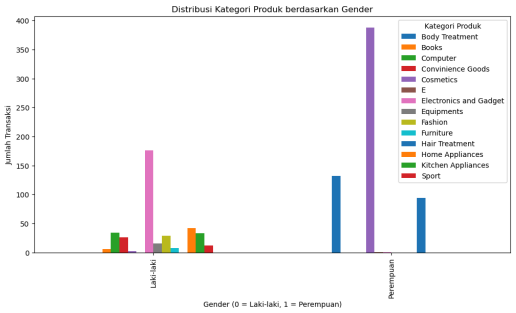

Gambar 10. Distribusi Kategori Produk Berdasarkan Gender

Gambar 10 menunjukkan distribusi pembelian kategori produk berdasarkan gender. Terlihat bahwa pelanggan perempuan lebih dominan pada sebagian besar kategori, terutama Cosmetics, Hair Treatment, dan Body Treatment. Sementara itu, kategori seperti Computer, Home Appliances, dan Electronics and Gadget menunjukkan jumlah transaksi yang lebih seimbang antara laki-laki dan perempuan. Secara umum, pola ini menunjukkan adanya perbedaan preferensi produk berdasarkan gender yang dapat dijadikan dasar dalam strategi pemasaran dan pengelolaan stok produk.

```
#cek untuk apakah ada kolom label
if 'is_repeat_buyer' in df.columns:
    print(df['is_repeat_buyer'].value_counts(normalize=True))
```

Gambar 11. Pengecekan Keberadaan Kolom is_repeat_buyer dalam Dataset

Kolom is_repeat_buyer tidak ditemukan pada dataset, sehingga analisis terkait pelanggan yang melakukan pembelian ulang (repeat buyer) tidak dapat dilakukan pada data ini. Untuk dapat menganalisis perilaku repeat buyer, diperlukan adanya kolom atau informasi tambahan yang menandai apakah seorang pelanggan melakukan pembelian lebih dari satu kali.

Pre-Processing Data

```
# buat kolom jumlah transaksi per customer
repeat_count = df['Cust_ID'].value_counts()
```

Gambar 12. Perhitungan Jumlah Transaksi per Customer

Pada tahap ini dilakukan proses perhitungan jumlah transaksi untuk setiap customer menggunakan fungsi value_counts(). Langkah ini bertujuan untuk mengetahui apakah seorang customer melakukan pembelian lebih dari satu kali. Informasi ini menjadi dasar untuk menentukan apakah customer tersebut termasuk repeat buyer atau bukan.

```
# buat kolom target
df['is_repeat_buyer'] = df['Cust_ID'].apply(lambda x: 1 if repeat_count[x] > 1 else 0)
```

Gambar 13. Pembentukan Variabel Target (is_repeat_buyer)

Selanjutnya dilakukan pembuatan variabel target bernama is_repeat_buyer, yang akan digunakan sebagai label pada proses data mining. Variabel ini dibentuk dengan memberikan nilai 1 apabila customer memiliki jumlah transaksi lebih dari satu kali (repeat buyer), dan nilai 0 apabila hanya melakukan satu transaksi. Tahap ini merupakan bagian dari feature engineering, yaitu proses mengubah data mentah menjadi fitur yang lebih bermakna untuk model.

```
# cek distribusinya
df['is_repeat_buyer'].value_counts()
```

```
is_repeat_buyer
1    989
0     11
Name: count, dtype: int64
```

Gambar 14. Analisis Distribusi Variabel Target

Setelah variabel target terbentuk, dilakukan pemeriksaan distribusi kelas menggunakan value_counts(). Hasil menunjukkan bahwa terdapat 989 transaksi dengan label repeat buyer dan 11 transaksi dengan label non-repeat buyer. Informasi ini juga mengindikasikan adanya ketidakseimbangan kelas (imbalanced data) yang perlu ditangani pada tahap selanjutnya.

```
df['Trx_Date'] = pd.to_datetime(df['Trx_Date'])
df['Year'] = df['Trx_Date'].dt.year
df['Month'] = df['Trx_Date'].dt.month
df['Day'] = df['Trx_Date'].dt.day
df['DayOfWeek'] = df['Trx_Date'].dt.dayofweek
```

Gambar 15. Feature Engineering pada Kolom Tanggal Transaksi

Pada tahap *pre-processing* ini dilakukan konversi kolom Trx_Date ke dalam tipe data datetime agar dapat diolah secara konsisten. Setelah itu dilakukan ekstraksi komponen waktu berupa tahun (Year), bulan (Month), hari (Day), dan hari ke-berapa dalam minggu (DayOfWeek). Proses ini bertujuan untuk menghasilkan fitur tambahan yang dapat mendukung analisis pola transaksi pada tahap data mining selanjutnya.

```
df = df.drop(['No', 'Cust_ID', 'Trx_Date'], axis=1)
```

Gambar 16. Penghapusan Kolom yang Tidak Digunakan

Pada gambar 16, dilakukan proses *data cleaning* dengan menghapus beberapa atribut yang tidak lagi diperlukan dalam analisis, yaitu No, Cust_ID, dan Trx_Date. Penghapusan kolom dilakukan untuk mengurangi atribut yang tidak relevan, menghindari redundansi, serta menyederhanakan dataset sehingga proses data mining selanjutnya dapat berjalan lebih efektif dan fokus pada fitur-fitur yang memiliki kontribusi terhadap pemodelan.

Transformation Data

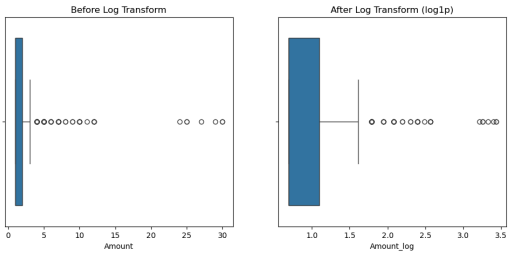

Gambar 17. Perbandingan distribusi variabel *Amount* sebelum dan sesudah dilakukan log transform

Gambar 17 menunjukkan perbandingan distribusi variabel *Amount* sebelum dan sesudah dilakukan transformasi logaritmik menggunakan metode log1p. Pada boxplot sebelum transformasi, terlihat bahwa nilai *Amount* memiliki sebaran yang sangat lebar dan terdapat beberapa titik outlier yang jauh dari mayoritas data. Kondisi ini mengindikasikan bahwa variabel *Amount* bersifat sangat skewed (condong ke kanan). Setelah dilakukan log transform, sebaran data tampak lebih terkompresi dan outlier menjadi lebih dekat ke pusat distribusi. Transformasi ini membantu menstabilkan varians, mengurangi skewness, serta membuat distribusi data lebih mendekati normal sehingga lebih cocok digunakan pada proses analisis dan pemodelan machine learning.

```
from sklearn.preprocessing import LabelEncoder

cat_cols = ['Gender', 'AREA', 'Product_ID', 'Product_Name', 'Category']

# Dictionary untuk menyimpan encoder tiap kolom
label_encoders = {}

for col in cat_cols:
    le = LabelEncoder()              # buat encoder baru per kolom
    df[col] = le.fit_transform(df[col])
    label_encoders[col] = le         # simpan encoder untuk nanti (prediksi & inverse)
```

Gambar 18. Proses Label Encoding pada Variabel Kategorikal

Pada gambar 18, dilakukan proses *label encoding* untuk mengubah variabel kategorikal menjadi representasi numerik. Proses ini dilakukan dengan membuat *encoder* terpisah untuk setiap kolom kategorikal, yaitu Gender, AREA, Product_ID, Product_Name, dan Category. Setiap nilai unik pada masing-masing kolom dikonversi ke dalam bentuk angka sehingga dataset dapat diproses oleh algoritma data mining yang hanya menerima input numerik. Selain itu, setiap encoder disimpan dalam sebuah dictionary untuk memastikan konsistensi transformasi pada saat proses prediksi maupun *inverse transform*.

	Age	Gender	AREA	Product_ID	Product_Name	Category	Amount	Amount_log	is_repeat_buyer	Year	Month	Day	DayOfWeek
0	49	0	0	59	54	2	1	0.693147	1	2022	6	1	2
1	18	1	2	14	19	10	1	0.693147	1	2022	6	1	2
2	42	1	4	14	19	10	7	2.079442	1	2022	6	1	2
3	42	0	6	63	82	11	5	1.791759	1	2022	6	1	2
4	39	1	9	19	77	4	1	0.693147	1	2022	6	1	2

Gambar 19. Hasil Transformasi Data Setelah Proses Encoding dan Feature Extraction

Gambar 19 di atas menunjukkan hasil akhir dari tahap *data transformation* yang meliputi proses *label encoding* pada variabel kategorikal, penambahan fitur hasil ekstraksi tanggal (Year, Month, Day, DayOfWeek), serta pembuatan fitur target is_repeat_buyer. Pada tahap ini, seluruh variabel kategorikal seperti Gender, AREA, Product_ID, Product_Name, dan Category telah dikonversi menjadi nilai numerik sehingga dapat digunakan sebagai input bagi algoritma data mining. Selain itu, fitur Amount_log merupakan hasil transformasi logaritmik untuk menormalkan distribusi data. Dataset yang telah terstruktur dalam bentuk numerik ini kemudian siap digunakan pada tahap *data mining* untuk proses pelatihan dan pengujian model.

```
Mapping untuk kolom: Gender
Laki-laki → 0
Perempuan → 1
```

Gambar 20. Hasil Mapping Label Encoding pada Kolom Gender

Gambar di atas menunjukkan proses *label encoding* yang diterapkan pada variabel kategorikal Gender sebagai bagian dari tahap *data transformation*. Dalam proses ini, nilai kategorikal diubah menjadi representasi numerik menggunakan objek LabelEncoder. Hasil encoding memperlihatkan bahwa nilai “Laki-laki” dikonversi menjadi kode numerik 0, sedangkan “Perempuan” dikonversi menjadi 1. Transformasi ini bertujuan untuk memastikan bahwa data kategorikal dapat diproses oleh algoritma data mining yang mensyaratkan input dalam bentuk numerik, serta menjaga konsistensi pemetaan nilai selama proses pelatihan dan prediksi model.

```
X = df.drop('is_repeat_buyer', axis=1)
y = df['is_repeat_buyer']
```

Gambar 21. Tahap Pemisahan Fitur (X) dan Target (y) pada

Pada tahap *data mining process*, dilakukan pemisahan antara variabel fitur (X) dan variabel target (y) untuk mempersiapkan data sebelum proses pelatihan model. Variabel fitur (X) berisi seluruh atribut yang digunakan sebagai input model, sedangkan variabel target (y) berisi label

is_repeat_buyer yang menunjukkan apakah seorang pelanggan termasuk ke dalam kategori *repeat buyer* atau tidak. Pemisahan ini merupakan langkah penting agar algoritma klasifikasi dapat mempelajari hubungan antara fitur dan target secara terstruktur selama proses pelatihan dan evaluasi model.

Data Mining Process

Pada tahap Data Mining Process, data yang telah diproses kemudian dibagi menjadi dua bagian, yaitu data training dan data testing. Pembagian ini dilakukan agar model dapat belajar pola dari data training dan diuji menggunakan data testing yang tidak pernah dilihat sebelumnya. Tujuannya adalah memastikan model mampu melakukan generalisasi dengan baik serta menghasilkan evaluasi yang objektif terhadap kinerjanya.

```
from sklearn.model_selection import train_test_split

X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, random_state=42, stratify=y
)
```

Gambar 22. Train–test split

Data dibagi menjadi data latih (training) dan data uji (testing) menggunakan fungsi train_test_split, dengan 20% data digunakan sebagai data uji dan sisanya untuk pelatihan. Pembagian dilakukan secara stratified berdasarkan variabel target y agar proporsi kelas pada data latih dan uji tetap sama, sehingga model dapat belajar dan diuji secara representatif terhadap kedua kelas.

```
X_train.dtypes
X_train.head()
```

	Age	Gender	AREA	Product_ID	Product_Name	Category	Amount	Amount_log	Year	Month	Day	DayOfWeek
174	19	1	10	28	71	4	2	1.098612	2022	6	11	5
79	44	0	29	70	37	11	1	0.693147	2022	6	5	6
216	27	0	27	54	113	7	1	0.693147	2022	6	13	0
544	18	1	20	20	120	4	1	0.693147	2022	7	3	6
868	47	0	27	34	121	6	1	0.693147	2022	7	23	5

Gambar 23. Menampilkan Tipe Data dan Cuplikan Awal Data Training (X_train)

Kode ini digunakan untuk memeriksa struktur data training (X_train). Perintah X_train.dtypes menampilkan tipe data dari setiap fitur untuk memastikan kesesuaian tipe sebelum proses pemodelan, sedangkan X_train.head() menampilkan beberapa baris awal data training sebagai verifikasi bahwa data telah terbagi dengan benar setelah tahap split dataset.

```
Before SMOTE: is_repeat_buyer
1    791
0      9
Name: count, dtype: int64
After SMOTE: is_repeat_buyer
1    791
0    791
Name: count, dtype: int64
```

Gambar 24. Penyeimbangan Kelas dengan SMOTE

Pada tahap ini digunakan SMOTE (Synthetic Minority Over-sampling Technique) untuk menangani ketidakseimbangan kelas pada variabel target is_repeat_buyer, di mana sebelum SMOTE kelas minoritas (0) hanya memiliki 9 sampel sedangkan kelas mayoritas (1) memiliki 791 sampel. SMOTE membuat sampel sintetis dari kelas minoritas sehingga jumlah sampel pada kedua kelas menjadi seimbang, masing-masing 791 sampel, sehingga model diharapkan dapat belajar lebih adil terhadap kedua kelas dan meningkatkan performa prediksi terutama untuk kelas minoritas.

```
from sklearn.preprocessing import StandardScaler

scaler = StandardScaler()
X_train_scaled = scaler.fit_transform(X_train_res)
X_test_scaled = scaler.transform(X_test)
```

Gambar 25. Proses Standarisasi Data Menggunakan StandardScaler

Pada tahap ini dilakukan proses standarisasi data menggunakan StandardScaler agar seluruh fitur numerik memiliki skala yang seragam (mean = 0, standar deviasi = 1). Scaling diterapkan pada data training menggunakan metode fit_transform, kemudian hasil standarisasi tersebut digunakan untuk mentransformasi data testing.

```
#modeling random forest
from sklearn.ensemble import RandomForestClassifier

model_rf = RandomForestClassifier(random_state=42)
model_rf.fit(X_train_scaled, y_train_res)
```

```
RandomForestClassifier
RandomForestClassifier(random_state=42)
```

Gambar 26. Proses Modeling dengan Algoritma Random Forest

Pada tahap modeling ini digunakan algoritma Random Forest, yaitu metode ensemble yang menggabungkan banyak decision tree untuk meningkatkan akurasi dan stabilitas prediksi. Model dibangun menggunakan

RandomForestClassifier dengan parameter *random_state=42* untuk memastikan replikasi hasil. Data latih yang telah melalui proses *scaling* serta penyeimbangan (*oversampling*) kemudian digunakan untuk melakukan *fit* terhadap model sehingga Random Forest dapat mempelajari pola dari fitur-fitur yang tersedia dan menghasilkan model prediksi yang lebih robust terhadap overfitting.

```
#Modeling Decision Tree
from sklearn.tree import DecisionTreeClassifier

model_dt = DecisionTreeClassifier(random_state=42)
model_dt.fit(X_train_scaled, y_train_res)
```

```
DecisionTreeClassifier
DecisionTreeClassifier(random_state=42)
```

Gambar 27. Proses Modeling dengan Algoritma Decision Tree

Pada tahap ini digunakan algoritma Decision Tree untuk membangun model klasifikasi berdasarkan aturan pemecahan data secara bertingkat. Algoritma ini dipilih karena mampu menangani data numerik maupun kategorikal serta memberikan interpretasi yang mudah dipahami melalui struktur pohonnya. Model dibuat menggunakan *DecisionTreeClassifier* dengan *random_state=42* agar hasil yang diperoleh konsisten. Selanjutnya, data latih yang telah dinormalisasi dan diseimbangkan digunakan untuk melakukan *fit* terhadap model sehingga Decision Tree dapat mempelajari pola keputusan dari dataset dan menghasilkan prediksi yang sesuai.

```
from sklearn.naive_bayes import GaussianNB

model_nb = GaussianNB()
model_nb.fit(X_train_scaled, y_train_res)
```

```
GaussianNB
GaussianNB()
```

Gambar 28. Proses Modeling dengan Algoritma Gaussian Naive Bayes

Pada tahap ini digunakan algoritma Gaussian Naive Bayes, yaitu metode klasifikasi berbasis probabilistik yang mengasumsikan bahwa setiap fitur saling independen dan berdistribusi normal. Model dibangun menggunakan *GaussianNB()* tanpa parameter khusus karena algoritma ini secara default sudah optimal untuk data berskala numerik. Data latih yang telah melalui proses *scaling* dan penyeimbangan kemudian digunakan untuk melakukan *fit* sehingga Gaussian Naive Bayes dapat menghitung probabilitas setiap kelas dan menghasilkan prediksi dengan proses yang cepat serta sederhana.

```
# Apply Model - Random Forest
y_pred_rf = model_rf.predict(X_test_scaled)
```

Gambar 29. Proses Penerapan Model Random Forest pada Data Uji

Pada tahap ini model Random Forest yang telah dilatih sebelumnya digunakan untuk melakukan prediksi terhadap data uji. Model ini bekerja dengan menggabungkan hasil dari banyak decision tree sehingga prediksi yang dihasilkan lebih stabil dan tahan terhadap overfitting. Melalui perintah model_rf.predict(X_test_scaled), Random Forest memanfaatkan pola yang telah dipelajari pada data latih untuk menentukan kelas akhir pada setiap record di data uji.

```
# Apply Model - Decision Tree
y_pred_dt = model_dt.predict(X_test_scaled)
```

Gambar 30. Proses Penerapan Model Decision Tree pada Data Uji

Model Decision Tree yang sudah dibangun kemudian diaplikasikan pada data uji untuk menghasilkan prediksi. Algoritma ini menentukan output dengan mengikuti cabang-cabang aturan yang terbentuk selama proses pelatihan. Perintah model_dt.predict(X_test_scaled) membuat model menelusuri struktur pohon keputusan dan memilih kelas berdasarkan node akhir yang sesuai dengan karakteristik data uji.

```
# Apply Model - Naive Bayes
y_pred_nb = model_nb.predict(X_test_scaled)
```

Gambar 31. Proses Penerapan Model Gaussian Naive Bayes pada Data Uji

Pada tahap ini model Gaussian Naive Bayes digunakan untuk memprediksi kelas dari data uji dengan menghitung probabilitas setiap kelas berdasarkan distribusi Gaussian. Melalui model_nb.predict(X_test_scaled), model memanfaatkan nilai mean dan variance dari fitur pada data latih untuk menentukan kelas dengan probabilitas tertinggi, sehingga prediksi dapat dilakukan secara cepat dan efisien.

Prediksi

```
# Prediksi - Random Forest
y_pred_rf = model_rf.predict(X_test_scaled)
print(y_pred_rf[:10])   # contoh 10 prediksi pertama
```

```
[1 1 1 1 1 1 1 1 1 1]
```

Gambar 32. Hasil Prediksi Model Random Forest pada 10 Data Uji Pertama

Model Random Forest menghasilkan prediksi kelas untuk 10 data uji pertama dengan output [1 1 1 1 1 1 1 1 1 1]. Hal ini menunjukkan bahwa seluruh sampel diprediksi sebagai kelas 1, yang dalam konteks penelitian berarti kategori *repeat buyer*. Konsistensi prediksi ini mencerminkan kecenderungan model Random Forest dalam mengidentifikasi pola pembelian berulang pada data uji.

```
# Prediksi - Decision Tree
y_pred_dt = model_dt.predict(X_test_scaled)
print(y_pred_dt[:10])
```

```
[1 1 1 1 1 1 1 1 1 1]
```

Gambar 33. Hasil Prediksi Model Decision Tree pada 10 Data Uji Pertama

Model Decision Tree juga menghasilkan prediksi [1 1 1 1 1 1 1 1 1 1] pada 10 data uji pertama. Seluruh data diklasifikasikan ke kelas 1 atau *repeat buyer*. Pola prediksi yang seragam ini menandakan bahwa struktur pohon keputusan lebih dominan mengenali ciri-ciri konsumen yang berpotensi melakukan pembelian ulang pada dataset uji.

```
# Prediksi - Naive Bayes
y_pred_nb = model_nb.predict(X_test_scaled)
print(y_pred_nb[:10])
```

```
[0 1 1 1 1 1 1 1 0 1]
```

Gambar 34. Hasil Prediksi Model Gaussian Naive Bayes pada 10 Data Uji Pertama

Berbeda dengan dua model sebelumnya, Gaussian Naive Bayes menghasilkan prediksi yang lebih bervariasi, yakni [0 1 1 1 1 1 1 1 0 1]. Terdapat dua sampel yang diprediksi sebagai kelas 0 (*non-repeat buyer*), sementara sisanya diprediksi sebagai *repeat buyer*. Variasi ini mencerminkan karakteristik Naive Bayes yang mengklasifikasikan berdasarkan probabilitas setiap fitur secara independen sehingga hasilnya dapat lebih beragam.

Evaluation

Metode evaluasi menggunakan Stratified K-Fold dipilih karena distribusi kelas pada dataset tidak seimbang, khususnya pada data uji yang hanya memiliki 9 sampel kelas non-repeat buyer. Untuk menghindari bias evaluasi dan ketidakstabilan hasil, Stratified K-Fold membagi dataset ke dalam beberapa fold dengan proporsi kelas yang sama di setiap pembagian. Proses ini menghasilkan penilaian model yang lebih representatif, stabil, dan tidak bergantung pada satu pembagian data saja.

```
from sklearn.model_selection import StratifiedKFold
from sklearn.metrics import accuracy_score, f1_score, roc_auc_score

skf = StratifiedKFold(n_splits=5, shuffle=True, random_state=42)
```

Gambar 35. Tahap Pembagian Data Menggunakan Stratified K-Fold

Pada tahap ini proses evaluasi dilakukan menggunakan Stratified K-Fold dengan jumlah *split* sebanyak 5 fold. Teknik ini membagi dataset menjadi lima bagian dengan tetap mempertahankan proporsi kelas yang seimbang pada setiap fold, sehingga masalah ketidakseimbangan kelas terutama karena jumlah kelas non-repeat buyer sangat sedikit dapat diminimalkan. Penggunaan Stratified K-Fold memastikan bahwa seluruh data mendapatkan giliran sebagai data latih maupun data uji sehingga menghasilkan proses evaluasi yang lebih stabil dan representatif.

```
models = {
    "Random Forest": model_rf,
    "Decision Tree": model_dt,
    "Naive Bayes": model_nb
}

results = {}

for name, model in models.items():
    accuracies = []
    f1_scores = []
    auc_scores = []

    for train_index, test_index in skf.split(X, y):
        X_train_fold, X_test_fold = X.iloc[train_index], X.iloc[test_index]
        y_train_fold, y_test_fold = y.iloc[train_index], y.iloc[test_index]

        # SMOTE hanya untuk training fold
        from imblearn.over_sampling import SMOTE
        smote = SMOTE(random_state=42)
        X_train_res, y_train_res = smote.fit_resample(X_train_fold, y_train_fold)

        # Scaling
        from sklearn.preprocessing import StandardScaler
        scaler = StandardScaler()
        X_train_scaled = scaler.fit_transform(X_train_res)
        X_test_scaled = scaler.transform(X_test_fold)

        # Train model
        model.fit(X_train_scaled, y_train_res)

        # Predict
        y_pred = model.predict(X_test_scaled)

        # Probabilities for AUC
        y_prob = model.predict_proba(X_test_scaled)[:, 1]
```

Gambar 36. Tahap Pelatihan dan Prediksi pada Setiap Fold

Pada setiap fold, data dilatih dan diuji secara terpisah dengan menerapkan beberapa langkah pemrosesan. Pertama, data training pada fold tersebut ditangani menggunakan SMOTE untuk mengatasi ketidakseimbangan kelas. Selanjutnya, dilakukan Standard Scaling agar fitur berada pada skala yang sama. Model kemudian dilatih menggunakan data hasil resampling dan diuji menggunakan data uji fold tersebut. Proses ini dilakukan berulang untuk ketiga model Random Forest, Decision Tree, dan Naive Bayes sehingga setiap model diuji secara konsisten pada lima skenario pembagian data yang berbeda.

```
        # Metrics
        accuracies.append(accuracy_score(y_test_fold, y_pred))
        f1_scores.append(f1_score(y_test_fold, y_pred))
        auc_scores.append(roc_auc_score(y_test_fold, y_prob))

    # Save results
    results[name] = {
        "Accuracy Mean": sum(accuracies)/len(accuracies),
        "F1 Mean": sum(f1_scores)/len(f1_scores),
        "AUC Mean": sum(auc_scores)/len(auc_scores),
    }

# Print hasil
for name, score in results.items():
    print("\n=== Hasil Stratified K-Fold:", name, "===")
    print("Rata-rata Accuracy:", score["Accuracy Mean"])
    print("Rata-rata F1 Score:", score["F1 Mean"])
    print("Rata-rata AUC:", score["AUC Mean"])
```

Gambar 37. Tahap Perhitungan Rata-rata Metrik Evaluasi Setiap Model

Tahap ini melakukan penghitungan tiga metrik evaluasi utama pada setiap fold, yaitu Accuracy, F1 Score, dan AUC. Nilai dari kelima fold kemudian dirata-ratakan untuk memperoleh performa keseluruhan setiap model. Pendekatan ini memberikan gambaran yang lebih menyeluruh mengenai kemampuan model dalam mengenali kedua kelas, terutama pada dataset yang tidak seimbang. Hasil evaluasi ini memungkinkan dilakukan perbandingan yang objektif antara ketiga model untuk menentukan algoritma dengan performa terbaik.

```
=== Hasil Stratified K-Fold: Random Forest ===
Rata-rata Accuracy: 0.9879999999999999
Rata-rata F1 Score: 0.9939596974772854
Rata-rata AUC: 0.6105496590268163

=== Hasil Stratified K-Fold: Decision Tree ===
Rata-rata Accuracy: 0.9640000000000001
Rata-rata F1 Score: 0.9815898837093039
Rata-rata AUC: 0.5368456134953596

=== Hasil Stratified K-Fold: Naive Bayes ===
Rata-rata Accuracy: 0.742
Rata-rata F1 Score: 0.8486122527353374
Rata-rata AUC: 0.5070450699892324
```

Gambar 38. Tahap Perhitungan Rata-rata Metrik Evaluasi Setiap Model

Berdasarkan evaluasi menggunakan metode Stratified K-Fold dengan 5 fold, diperoleh bahwa model Random Forest menunjukkan performa paling unggul dibandingkan dua model lainnya. Random Forest memperoleh nilai rata-rata Accuracy sebesar 0.988, F1 Score sebesar 0.994, serta AUC sebesar 0.611, menandakan kemampuan model yang kuat dalam mengenali kelas repeat buyer pada data yang tidak seimbang. Decision Tree berada pada posisi kedua dengan Accuracy 0.964 dan F1 Score 0.982, meskipun nilai AUC-nya lebih rendah yaitu 0.537. Sementara itu, model Naive Bayes memiliki performa paling rendah dengan Accuracy 0.742, F1 Score 0.849, dan AUC 0.507, menunjukkan bahwa model ini kurang optimal dalam membedakan kedua kelas pada dataset tersebut.

CONCLUSION

Berdasarkan seluruh tahapan penelitian, mulai dari pengumpulan data, pra-pemrosesan, transformasi data, hingga pemodelan dan evaluasi, dapat disimpulkan bahwa penelitian ini berhasil membangun model klasifikasi untuk memprediksi pelanggan yang berpotensi menjadi *repeat buyer* pada platform e-commerce. Dataset yang digunakan memiliki kualitas baik tanpa nilai hilang ataupun duplikasi, sehingga proses pembersihan dapat dilakukan secara efisien. Analisis awal menunjukkan bahwa variabel *Amount* memiliki distribusi yang tidak normal serta mengandung *outlier*, sehingga diperlukan transformasi logaritmik untuk menstabilkan sebaran datanya. Selain itu, ketidakseimbangan kelas pada variabel target berhasil diatasi menggunakan teknik SMOTE, yang terbukti meningkatkan kemampuan model dalam mengenali kelas minoritas.

Tahapan pra-pemrosesan lain seperti *label encoding*, *feature engineering* pada tanggal transaksi, dan standarisasi menggunakan *StandardScaler* menghasilkan dataset yang lebih representatif untuk proses pemodelan. Tiga algoritma klasifikasi, yaitu Random Forest, Decision Tree, dan Gaussian Naive Bayes, diuji menggunakan pendekatan *Stratified K-Fold* untuk memastikan evaluasi lebih stabil dan mencerminkan distribusi kelas yang tidak seimbang.

Hasil evaluasi menunjukkan bahwa Random Forest merupakan model dengan performa terbaik, dengan rata-rata *accuracy* sebesar 0.988, *F1-score* sebesar 0.994, dan AUC sebesar 0.611. Model ini mampu menangani kompleksitas data dan ketidakseimbangan kelas dengan lebih baik dibandingkan dua algoritma lainnya. Decision Tree berada di posisi kedua dengan performa cukup baik namun memiliki kemampuan diskriminasi yang lebih rendah berdasarkan nilai AUC. Sementara itu, Gaussian Naive Bayes menunjukkan performa terendah, menandakan bahwa asumsi independensi antar fitur tidak sesuai dengan karakteristik dataset.

Secara keseluruhan, penelitian ini menegaskan bahwa kombinasi teknik pra-pemrosesan yang tepat, penanganan ketidakseimbangan data, serta pemilihan algoritma yang sesuai sangat berpengaruh terhadap kualitas prediksi. Berdasarkan hasil

komparasi, Random Forest direkomendasikan sebagai model utama dalam mendukung pengambilan keputusan terkait identifikasi pelanggan yang berpotensi menjadi *repeat buyer*. Temuan ini diharapkan dapat membantu perusahaan e-commerce dalam merancang strategi retensi pelanggan yang lebih efektif, efisien, dan tepat sasaran.

ACKNOWLEDGEMENT

REFERENCES

[1]. DHL, “Customer retention: How to convert one-time buyers into loyal customers,” DHL Discover, 2024. [Online]. Available: https://www.dhl.com/discover/id-id/e-commerce-advice/e-commerce-best-practice/customer-retention-convert-loyal-customer

[2]. S. F. Mauludiah, C. Crysdian, and Y. M. Arif, “Enhancing Repeat Buyer Classification with Multi Feature Engineering in Logistic Regression,” *Applied Information System and Management*, vol. 8, no. 1, pp. 103–110, 2025, doi: https://doi.org/10.15408/aism.v8i1.45025

[3]. F. Saputra and Fersellia, *“*Prediction Customer Loyalty Using Random Forest Algorithm on Shopee Reviews*,” Paradigma,* vol. 27, no. 1, pp. 11-20, 2025, doi: https://doi.org/10.31294/p.v27i1.7940

[4]. M. A. A. Hakim and T. Terttiaavini, “Predictive Buyer Behavior Model as Customer Retention Optimization Strategy in E-commerce,” *INSYST: Journal of Intelligent System and Computation*, vol. 6, no. 1, pp. 32–38, 2024, doi: https://doi.org/10.52985/insyst.v6i1.379

[5]. A. C. Dewi, A. Hermawan, and D. Avianto, “Classification of Customers’ Repeat Order Probability Using Decision Tree, Naïve Bayes and Random Forest,” *Pilar Nusa Mandiri : Journal of Computing and Information System*, vol. 20, no. 1, pp. 52–59, 2024, doi: https://doi.org/10.33480/pilar.v20i1.5243

[6]. Y. Suhanda, L. Nurlaela, I. Kurniati, A. Dharmalau, and I. Rosita, “Predictive Analysis of Customer Retention Using the Random Forest Algorithm,” *TIERS: Information Technology Journal*, vol. 3, no. 1, pp. 35-47, 2022, doi: https://doi.org/10.38043/tiers.v3i1.3616

[7]. C. A. Samosir, “Strategi Customer Relationship Management untuk Meningkatkan Retensi Pelanggan di Era Digital,” *Repeater: Publikasi Teknik Informatika dan Jaringan*, vol. 3, no. 1, pp. 160–173, 2025, doi: https://doi.org/10.62951/repeater.v3i1.369

[8]. A. Sandu, L.-A. Cotfas, C. Ioanăș, I.-D. Cișmașu, and C. Delcea, “E-Commerce Meets Emerging Technologies: An Overview of Research Characteristics, Themes, and Trends,” *Journal of Theoretical and Applied Electronic Commerce Research*, vol. 20, no. 4, pp. 1–54, 2025, doi: https://doi.org/10.3390/jtaer20040320 .

[9]. C. Popescu, M. R. Gabor, and A. Stancu, “E-Commerce Revolution: How the Pandemic Reshaped the US Consumer Shopping Habits: A PACF and ARIMA Approach,” *Systems*, vol. 13, no. 9, pp. 1-46, 2025, doi: https://doi.org/10.3390/systems13090802

[10]. L. Duan, “Machine Learning Modeling for Forecasting Repeat Purchases in Online Shopping”, *MALCOM*, vol. 4, no. 3, pp. 863-874, 2024, doi: https://doi.org/10.57152/malcom.v4i3.1388

[11]. E. Kuric, A. Puskas, P. Demcak, and D. Mensatorisova, “Effect of Low-Level Interaction Data in Repeat Purchase Prediction Task,” *International Journal of Human–Computer Interaction*, vol. 40, no. 10, pp. 2515-2533, 2023, doi: https://doi.org/10.1080/10447318.2023.2175973 .

[12]. A. Pireddu, A. Bedini, M. Lombardi, A. L. C. Ciribini, and D. Berardi, “A Review of Data Mining Strategies by Data Type, with a Focus on Construction Processes and Health and Safety Management,” *Int. J. Environ. Res. Public Health*, vol. 21, no. 7, p. 831, 2024, doi: https://doi.org/10.3390/ijerph21070831

[13]. R. M. Sabbagh, H. A. Alzoubi, and M. Obeidat, “Applications and Competitive Advantages of Data Mining and Business Intelligence in SMEs Performance: A Systematic Review,” *Businesses*, vol. 5, no. 2, 2025, doi: https://doi.org/10.3390/businesses5020022

[14]. N. N. Adnan and M. K. Awang, “A Review on Classification Algorithm for Customer Churn Classification,” *International Journal of Recent Technology and Engineering (IJRTE)*, vol. 13, no. 1, 2024, doi: https://doi.org/10.35940/ijrte.A8030.13010524

[15]. Y. Wijaya and H. Pratiwi, “Comparison of Machine Learning Classification Algorithms,” Statistika: Journal of Theoretical and Applied *Statistics*, vol. 23, no. 1, pp. 55–66, 2023.

[16]. R. A. Saputri, A. Asrianda, and L. Rosnita, "A Random Forest-Based Predictive Model for Student Academic Performance: A Case Study in Indonesian Public High Schools", *JAIC*, vol. 9, no. 3, pp. 1042–1049, 2025, doi: https://doi.org/10.30871/jaic.v9i3.9460

[17]. D. Lestari, A. Nurhadi, and M. Kurniawan, "Random Forest Regression Algorithm in Predicting Economic Indicators," *Jurnal Teknologi dan Sistem Informasi*, vol. 11, no. 2, pp. 44–53, 2025.

[18]. R. D. Mandasari and H. Hartana, "Implementation Of Decision Tree Algorithm For Classification Of Eligibility In Social Assistance Fund Distribution", *TIERS*, vol. 5, no. 1, pp. 34-40, 2024, doi: https://doi.org/10.38043/tiers.v5i1.5378

[19]. L. Gomez, R. Ahmed, and S. Kapoor, "Decision Tree-Based Machine Learning Algorithm for Predictive Analytics," *Journal of Computational Intelligence*, vol. 12, no. 2, pp. 101–112, 2025.

[20]. F. Rahmawati and L. Yuliana, "Application of the Naive Bayes Method for Determining Classification Outcomes," *Jurnal IT Science*, vol. 6, no. 1, pp. 22–30, 2024.

[21]. Y. P. Astuti, A. R. Wibowo, E. Kartikadarma, E. R. Subhiyakto, N. A. Sri Winarsih, and M. S. Rohman, "Penerapan Metode Naïve Bayes Classifier untuk Klasifikasi Sentimen pada Judul Berita", *Logiclink*, vol. 1, no. 1, pp. 1–12, 2024, doi: https://doi.org/10.28918/logiclink.v1i1.7684

[22]. A. A. Syam, "Analisis Teknik Preprocessing pada Sentimen Masyarakat Terkait Konflik Israel–Palestina Menggunakan Support Vector Machine," *JIPI: Jurnal Ilmiah Pendidikan dan Informatika*, vol. 9, no. 3, pp. 1464-1472, 2024, doi: https://doi.org/10.29100/jipi.v9i3.5527

[23]. D. Rifaldi, A. Fadlil, and Herman, "Teknik Preprocessing pada Text Mining Menggunakan Data Tweet 'Mental Health'," *DECODE: Jurnal Pendidikan Teknologi Informasi*, vol. 3, no. 2, 2023, doi: http://dx.doi.org/10.51454/decode.v3i2.131

[24]. N. P. N. Fauzi, S. Khomsah, and A. D. P. Wicaksono, "Penerapan Feature Engineering dan Hyperparameter Tuning untuk Meningkatkan Akurasi Model Random Forest pada Klasifikasi Risiko Kredit", *Jurnal Teknologi Informasi dan Ilmu Komputer*, vol. 12, no. 2, pp. 251-262, 2025, doi: https://doi.org/10.25126/jtiik.2025128472

[25]. M. N. N. Pribadi and I. Ernawati, "Perbandingan Hasil Penerapan Algoritma Klasifikasi dan Natural Language Processing terhadap Data Kepuasan Pengguna Layanan Transportasi Umum MRT Jakarta," *Jurnal Informatik*, vol. 20, no. 3, pp. 102-111, 2024, doi:https://doi.org/10.52958/iftk.v20i3.10502

[26]. M. A. Salwa and Malabay, "Optimasi Model Algoritma Klasifikasi Data Mining Menggunakan Metode Feature Selection untuk Prediksi Penyakit Stroke," *Jurnal TEKINFO*, vol. 26, no. 1, pp. 11-20, 2025, doi: https://doi.org/10.37817/tekinfo.v26i1.4677

[27]. M. Trifena, N. Heryana, and T. Ridwan, "Penerapan Algoritma Apriori pada Transaksi Penjualan Air Minum untuk Meningkatkan Strategi Bisnis (Studi Kasus: PT Sila Tirta Gemilang)," *Jurnal Rekayasa Informasi Swadharma*, vol. 4, no. 2, pp. 37-46, 2024, doi:https://doi.org/10.56486/jris.vol4no2.535

[28]. L. Hakim, A. Sobri, L. Sunardi, and D. Nurdiansyah, "Prediksi Penyakit Jantung Berbasis Machine Learning dengan Menggunakan Metode K-NN," *Jurnal Digital Teknologi Informasi*, vol. 7, no. 2, pp. 14–20, 2024, doi: https://doi.org/10.32502/digital.v7i2.9429